PROJET ACADÉMIQUE • ASSURANCE NON-VIE

Tarification en assurance automobile

Modèle collectif : GLM de Poisson (fréquence) et GLM Gamma (coût moyen), prime pure et comparaison avec XGBoost

---

Auteur : Salah Fidah

Formation : Master Actuariat et Finance des Marchés, FSJES Aïn Sebaâ
Établissement : Université Hassan II de Casablanca

Données : freMTPL2 (portefeuille d'assurance auto français)
Outils : Python (pandas, numpy, statsmodels, scikit-learn, XGBoost, matplotlib)

Date : octobre 2026

Résumé. À partir de 678 013 contrats d'assurance automobile et de 26 639 sinistres, ce travail construit une prime pure individualisée selon le modèle collectif : un GLM de Poisson pour la fréquence et un GLM Gamma pour le coût moyen. Les résultats montrent un effet marqué du bonus-malus, de la zone et du jeune âge sur la fréquence, une surdispersion (dispersion $\approx 2{,}9$) corrigée par un quasi-Poisson, et la nécessité de plafonner les sinistres extrêmes (trois sinistres supérieurs à 1 M€ concernant des conducteurs de 18 à 20 ans). La prime pure moyenne est de 138 € par année-risque. Sur un échantillon test de 20 %, la charge totale est sous-estimée de 6,6 % et le classement des risques est cohérent ; XGBoost n'améliore la déviance de Poisson que de 1,3 %.

Table des matières

1 Introduction **2**

2 Cadre théorique **2**

3 Données et préparation **3**

4 Analyse exploratoire **4**

5 Modèle de fréquence **5**

6 Modèle de coût moyen **6**

7 Prime pure **8**

8 Validation sur échantillon test **9**

9 Comparaison avec XGBoost **10**

10 Limites et perspectives **11**

11 Conclusion **11**

A Organisation du code **11**

1 Introduction

1.1 Contexte

En assurance non-vie, le prix d'un contrat doit refléter le risque de l'assuré. L'assureur ne connaît pas à l'avance les sinistres futurs : il estime leur espérance, la *prime pure*, qui correspond au prix « juste » avant frais de gestion, commissions et marge. Plus cette estimation est fine, plus la tarification est équitable : les bons risques ne subventionnent pas les mauvais.

1.2 Problématique

> Comment construire une tarification individualisée en assurance automobile, en estimant la prime pure de chaque assuré à partir de ses caractéristiques, et dans quelle mesure un modèle collectif fondé sur deux GLM (Poisson pour la fréquence, Gamma pour le coût moyen) est-il performant et fiable par rapport à une méthode de machine learning (XGBoost) ?

Quatre sous-questions guident l'étude :

1. Quels facteurs de risque influencent la fréquence et le coût des sinistres ?
2. Les hypothèses du modèle (loi de Poisson, effets multiplicatifs) sont-elles acceptables ?
3. Le modèle prédit-il correctement la charge sur des contrats qu'il n'a jamais vus ?
4. Un modèle de machine learning apporte-t-il un gain réel par rapport au GLM ?

1.3 Plan

La section 2 rappelle le cadre théorique. La section 3 présente les données et leur préparation, la section 4 l'analyse exploratoire. Les sections 5 et 6 construisent les modèles de fréquence et de coût, la section 7 la prime pure, la section 8 sa validation et la section 9 la comparaison avec XGBoost. La section 10 discute les limites.

2 Cadre théorique

2.1 Le modèle collectif

La charge totale S d'un contrat sur une période s'écrit

$$S = \sum_{k=1}^{N} X_k,$$

où N est le nombre de sinistres (variable discrète) et X_k le coût du k-ième sinistre (variable positive continue), avec $S = 0$ si $N = 0$. Sous les hypothèses classiques (les X_k sont indépendants et de même loi, et indépendants de N), on obtient

$$\mathbb{E}[S] = \mathbb{E}[N] \times \mathbb{E}[X] = \lambda \times \mu.$$

La **prime pure** est donc le produit de la fréquence moyenne λ par le coût moyen μ.

2.2 Les modèles linéaires généralisés

Un GLM combine trois éléments : une loi de la famille exponentielle pour la variable à expliquer, un prédicteur linéaire $\eta = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p$, et une fonction de lien g telle que $g(\mathbb{E}[Y]) = \eta$. Avec le lien logarithmique, $\mathbb{E}[Y] = \exp(\eta)$: la prédiction est toujours positive et les effets des variables

se *multiplient*, ce qui correspond à la logique des grilles tarifaires. Pour une modalité j, la quantité $\exp(\beta_j)$ est appelée *relativité* : elle mesure le rapport de risque par rapport à la modalité de référence. Les coefficients sont estimés par maximum de vraisemblance, par l'algorithme des moindres carrés pondérés itérés (IRLS).

2.3 Modèle de fréquence

Le nombre de sinistres du contrat i, exposé pendant une durée e_i (en années), suit

$$N_i \sim \mathcal{P}(\lambda_i e_i), \qquad \ln \lambda_i = \beta_0 + \sum_j \beta_j x_{ij}.$$

On utilise donc $\ln(e_i)$ comme *offset* : un contrat couvert trois mois a, à risque égal, quatre fois moins de chances d'enregistrer un sinistre qu'un contrat couvert un an. La loi de Poisson impose $\mathrm{Var}(N) = \mathbb{E}[N]$; lorsque la variance observée est plus grande, on parle de *surdispersion*, mesurée ici par le rapport $\chi^2_{\text{Pearson}}/\text{ddl}$.

2.4 Modèle de coût moyen

Le coût moyen $\bar{X}_i$ des sinistres du contrat i est modélisé par une loi Gamma de moyenne μ_i avec lien logarithmique :

$$\ln \mu_i = \gamma_0 + \sum_j \gamma_j x_{ij}, \qquad \mathrm{Var}(\bar{X}_i) = \phi\, \mu_i^2.$$

Cette loi convient à une variable positive, asymétrique, dont l'écart-type est proportionnel à la moyenne. Le modèle est estimé uniquement sur les contrats ayant au moins un sinistre, pondérés par leur nombre de sinistres.

2.5 Prime pure individuelle

Pour le contrat i : $\hat{P}_i = \hat{\lambda}_i \times \hat{\mu}_i$, exprimée en euros par année-risque.

3 Données et préparation

3.1 Présentation de freMTPL2

Le jeu de données freMTPL2 décrit un portefeuille d'assurance responsabilité civile automobile en France. Il comprend deux tables liées par l'identifiant de police `IDpol` : la table *fréquence* (678 013 contrats, une ligne par contrat) et la table *sévérité* (26 639 sinistres, une ligne par sinistre avec son montant). Aucune valeur manquante n'a été détectée.

Variable	Description
`ClaimNb`	nombre de sinistres du contrat
`Exposure`	durée de couverture, en années
`Area`	densité de la zone, de A (rural) à F (très urbain)
`VehPower`, `VehAge`	puissance et âge du véhicule
`DrivAge`	âge du conducteur
`BonusMalus`	coefficient bonus-malus (100 = neutre sur cette échelle)
`VehBrand`, `VehGas`	marque et carburant du véhicule
`Density`, `Region`	densité de population de la ville, région
`ClaimAmount`	(table sévérité) montant d'un sinistre

Tab. 1. Variables des deux tables.

3.2 Une sinistralité faible

Sur les 678 013 contrats, 643 953 (environ 95 %) n'ont aucun sinistre, 32 178 en ont un et 1 784 en ont deux. L'exposition totale est de 358 499 années-risque, pour une exposition moyenne de 0,53 an par contrat : de nombreux contrats ne couvrent qu'une partie de l'année. Cette sinistralité rare et discrète justifie le recours à la loi de Poisson.

3.3 Traitement des valeurs atypiques

Deux anomalies ont été corrigées par plafonnement :

- **Exposition** : 1 224 contrats ont une exposition supérieure à 1 an, ce qui est incohérent avec une observation annuelle ; elle est ramenée à 1.
- **Nombre de sinistres** : 9 contrats ont plus de 4 sinistres (jusqu'à 16) ; ils sont ramenés à 4, convention courante sur ce jeu de données, pour que quelques cas extrêmes n'influencent pas le modèle.

Ces corrections concernent moins de 0,2 % du portefeuille. La fréquence globale devient $0{,}1006$ sinistre par année-risque, soit environ 10 sinistres pour 100 années de couverture.

3.4 Jointure des tables et écart de comptage

Les montants sont additionnés par contrat puis rattachés à la table fréquence grâce à `IDpol`. Cette étape a révélé un écart : la somme de `ClaimNb` vaut 36 056 sinistres, alors que seuls 26 444 sinistres ont un montant dans la table sévérité. Un premier calage, qui combinait la fréquence issue de `ClaimNb` et le coût issu des montants, surestimait la charge totale de 34 % (66,9 M€ prédits contre 50,0 M€ observés). La correction retenue consiste à compter les sinistres comme *les lignes présentes dans la table sévérité* (variable `Nb`), afin que fréquence et coût portent sur les mêmes événements. La cause exacte de l'écart n'est pas documentée dans les données ; elle est signalée comme limite en section 10 (modèle limité aux sinistres dont le montant est renseigné).

4 Analyse exploratoire

Les variables continues (âge du conducteur, bonus-malus) sont découpées en classes, car le GLM suppose un effet log-linéaire. La fréquence est ensuite calculée par groupe comme le rapport du nombre de sinistres à l'exposition.

Zone	Contrats	Sinistres	Exposition	Fréquence
A	103 957	5 056	61 957	0,0816
B	75 459	3 800	43 002	0,0884
C	191 880	9 875	104 403	0,0946
D	151 596	8 390	77 088	0,1088
E	137 167	7 804	63 786	0,1223
F	17 954	1 131	8 125	0,1392

Tab. 2. Fréquence par zone (sinistres par année-risque, fréquence globale 0,1006).

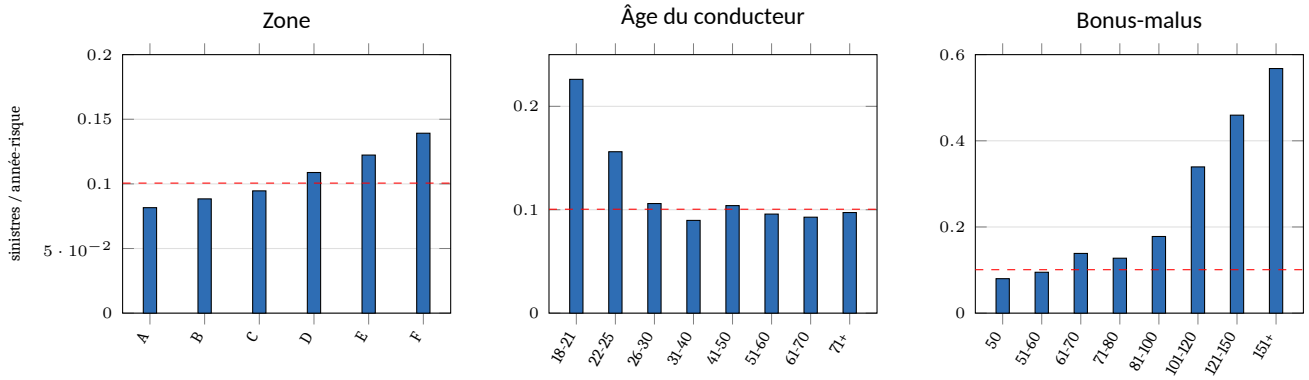


Fig. 1. Fréquence par zone, âge du conducteur et bonus-malus. La ligne rouge pointillée est la fréquence globale (0,1006).

Lecture.

- **Zone** : la fréquence augmente régulièrement de A à F ; elle est environ 1,7 fois plus élevée en zone F qu'en zone A.
- **Âge** : la fréquence est la plus élevée chez les 18–21 ans (0,226), environ 2,5 fois celle des 31–40 ans (0,090), avec une forme en U : elle remonte légèrement après 70 ans.
- **Bonus-malus** : c'est la variable la plus discriminante, la fréquence étant multipliée par plus de 7 entre la meilleure et la pire classe. Ce coefficient étant calculé à partir de la sinistralité passée, il résume en partie le comportement du conducteur.
- **Carburant** : 0,0975 (diesel) contre 0,1034 (essence), un écart faible.

Ces tableaux examinent une variable à la fois ; les variables étant corrélées (par exemple jeunes conducteurs et malus), c'est le GLM qui isole l'effet propre de chacune. Les classes extrêmes sont de petite taille (209 contrats pour la classe de bonus-malus la plus élevée), donc moins fiables.

5 Modèle de fréquence

5.1 Spécification

Le GLM de Poisson explique `ClaimNb` par la zone, l'âge du conducteur en classes et le bonus-malus en classes, avec l'offset $\ln(\text{Exposure})$. Les modalités de référence sont la zone A, les 18–21 ans et la classe de bonus-malus (100,120]. Une première version incluait le carburant ; sa relativité (1,005, $p = 0{,}66$) étant nulle, la variable a été retirée.

5.2 Surdispersion et correction

Le rapport $\chi^2_{\text{Pearson}}/\text{ddl}$ vaut **2,88**, très supérieur à 1 : la variance des sinistres est près de trois fois plus grande que ne le prévoit la loi de Poisson. Une explication classique est l'hétérogénéité non observée entre assurés de même profil (style de conduite, kilométrage), mais les données ne permettent pas de la démontrer. Un modèle **quasi-Poisson** conserve les coefficients (et donc les primes) mais multiplie les erreurs standard par $\sqrt{2{,}88} \approx 1{,}7$, ce qui rend les p-values plus réalistes. La déviance du modèle vaut 218 157,9 et son AIC 287 514,4.

5.3 Résultats

Variable	Modalité	Coefficient	Relativité	p (quasi-Poisson)
	Constante	$-1{,}0429$	0,352	$< 0{,}001$
Zone (réf. A)	B	0,0680	1,070	0,062
	C	0,1162	1,123	$< 0{,}001$
	D	0,2044	1,227	$< 0{,}001$
	E	0,2808	1,324	$< 0{,}001$
	F	0,3777	1,459	$< 0{,}001$
Âge (réf. 18–21)	22–25	$-0{,}2798$	0,756	$< 0{,}001$
	26–30	$-0{,}4527$	0,636	$< 0{,}001$
	31–40	$-0{,}3217$	0,725	$< 0{,}001$
	41–50	0,0175	1,018	0,775
	51–60	$-0{,}0229$	0,977	0,714
	61–70	$-0{,}0266$	0,974	0,688
	71 et plus	0,0450	1,046	0,510
Bonus-malus (réf. 101–120)	50	$-1{,}5719$	0,208	$< 0{,}001$
	51–60	$-1{,}2788$	0,278	$< 0{,}001$
	61–70	$-0{,}8910$	0,410	$< 0{,}001$
	71–80	$-0{,}9397$	0,391	$< 0{,}001$
	81–100	$-0{,}6458$	0,524	$< 0{,}001$
	121–150	0,2850	1,330	0,005
	151 et plus	0,4438	1,559	0,062

Tab. 3. GLM de Poisson de fréquence : coefficients, relativités $\exp(\beta)$ et p-values corrigées de la surdispersion.

5.4 Interprétation

- **Zone** : toutes choses égales par ailleurs, un assuré de la zone F a un risque environ 46 % plus élevé qu'en zone A. L'effet est régulier et significatif de C à F ; la zone B ne l'est plus après correction de la surdispersion ($p = 0{,}062$).
- **Bonus-malus** : c'est l'effet dominant. Un assuré au meilleur bonus (50) a un risque environ cinq fois plus bas ($1/0{,}208 \approx 4{,}8$) que celui de la classe de référence (101–120). Cette forte capacité à discriminer est liée au fait que le coefficient est construit à partir des sinistres passés.
- **Âge** : les 22–40 ans ont un risque inférieur d'environ 24 à 36 % à celui des 18–21 ans. À partir de 41 ans, le modèle ne détecte plus de différence avec les 18–21 ans. Ce résultat contraste avec l'analyse exploratoire, où les jeunes se distinguaient fortement : une partie de l'effet de l'âge est portée par le bonus-malus, que le modèle prend en compte. Je le présente comme une hypothèse ; d'autres découpages d'âge ou des interactions permettraient de l'approfondir.
- **Classes fragiles** : la classe de bonus-malus la plus élevée ne comprend que 209 contrats ($p = 0{,}062$) ; regrouper (121,150] et (151,230] serait une amélioration possible.

6 Modèle de coût moyen

6.1 Première estimation et anomalie

Le GLM Gamma (lien logarithmique, pondération par le nombre de sinistres) est estimé sur les 24 944 contrats ayant au moins un sinistre avec montant. Le coût moyen par sinistre est de 2 222 €. Cependant,

toutes les classes d'âge ressortent avec une relativité d'environ 0,2 par rapport aux 18–21 ans, c'est-à-dire un sinistre cinq fois plus coûteux chez les jeunes, résultat peu crédible ; l'intercept (9 795 €) est aussi très éloigné de la moyenne, et le paramètre d'échelle vaut 24,3.

6.2 Diagnostic : les sinistres extrêmes

La table sévérité montre une distribution à queue très lourde.

Indicateur	Valeur (€)
Médiane	1 172
Moyenne	2 279
Maximum	4 075 401

Tab. 4. Distribution des montants de sinistres (26 639 sinistres).

Le plus gros sinistre vaut environ 3 500 fois la médiane, et les 20 plus gros représentent 19,3 % du montant total. Surtout, les trois plus grands sinistres (4,08 M€, 1,40 M€ et 1,30 M€) concernent des conducteurs de 19, 20 et 18 ans, tous dans la classe de référence. Ces trois cas suffisent à gonfler le coût moyen de cette classe et expliquent l'anomalie précédente.

6.3 Plafonnement et robustesse

Un GLM Gamma n'est pas adapté à de tels montants. Chaque sinistre est donc plafonné à un seuil, deux seuils étant comparés.

Plafond par sinistre	Coût moyen (€)	Relativités d'âge
Aucun	2 279	$\approx$ 0,19 – 0,29 (peu crédible)
100 000 €	1 864	0,61 – 0,69 (70+ : 0,88, non signif.)
50 000 €	1 754	0,68 – 0,75 (70+ : 0,89, non signif.)

Tab. 5. Effet du plafonnement sur le coût moyen et sur l'effet de l'âge.

Les conclusions sont stables d'un seuil à l'autre. Le seuil de **100 000 €** est retenu : il corrige le problème en retirant le moins d'information. Il s'agit d'un choix de modélisation à justifier ; il supprime une part de la charge réelle, qu'un assureur recouvrirait par un chargement spécifique pour sinistres graves.

6.4 Résultats avec plafond de 100 000 €

		Plafond 100 000 €		Plafond 50 000 €	
Variable	**Modalité**	**Relativité**	p	**Relativité**	p
	Constante (€)	2 993	$< 0{,}001$	2 487	$< 0{,}001$
Zone	B	0,894	0,114	0,973	0,615
	C	0,886	0,035	0,936	0,133
	D	0,958	0,465	1,004	0,933
	E	0,966	0,556	1,021	0,644
	F	0,752	0,009	0,799	0,008
Âge	22–25	0,614	$< 0{,}001$	0,678	$< 0{,}001$
	26–30	0,644	$< 0{,}001$	0,714	$< 0{,}001$
	31–40	0,690	$< 0{,}001$	0,742	$< 0{,}001$
	41–50	0,643	$< 0{,}001$	0,721	$< 0{,}001$
	51–60	0,679	$< 0{,}001$	0,754	0,001
	61–70	0,659	$< 0{,}001$	0,719	$< 0{,}001$
	71 et plus	0,881	0,299	0,891	0,221
Bonus-malus	50	0,933	0,507	0,926	0,345
	51–60	0,966	0,751	0,966	0,685
	61–70	0,890	0,291	0,901	0,226
	71–80	1,099	0,395	1,051	0,564
	81–100	1,050	0,645	1,028	0,740
	121–150	0,908	0,564	0,923	0,535
	151 et plus	1,345	0,440	1,391	0,268

Tab. 6. GLM Gamma du coût moyen : relativités par rapport aux modalités de référence (zone A, 18–21 ans, bonus-malus 101–120).

Interprétation. Seul l'âge du conducteur a un effet significatif sur le coût : un sinistre d'un conducteur de 22 à 70 ans coûte en moyenne 25 à 40 % de moins que celui d'un 18–21 ans, sauf après 70 ans où la différence n'est pas significative. Le bonus-malus, déterminant pour la fréquence, n'explique pas le coût : il renseigne sur la survenue des sinistres, pas sur leur gravité. La zone F semble associée à des sinistres moins coûteux ($p < 0{,}01$), sans explication possible avec ces données ; ce résultat ne doit pas être surinterprété.

7 Prime pure

Pour chaque contrat, la prime pure annuelle est le produit de la fréquence prédite (pour une exposition de 1 an) et du coût moyen prédit. Les deux modèles sont reconstruits sur la même variable de comptage `Nb` (section 3.4).

Indicateur	Valeur
Charge observée (sinistres plafonnés)	49 302 196 €
Charge prédite par le modèle	49 318 231 €
Écart	0,0 %
Prime pure moyenne	137,6 € par année-risque
Prime pure minimale	46,6 €
Prime pure maximale	3 330,6 €

Tab. 7. Prime pure sur l'ensemble du portefeuille.

L'écart nul sur les données d'estimation est attendu : un GLM de Poisson avec lien logarithmique reproduit la charge totale observée. Ce n'est donc pas une preuve de qualité, qui relève de la validation sur données non vues (section 8). Le rapport d'environ 70 entre la prime maximale et la prime minimale provient surtout du bonus-malus. Ces primes sont des primes *pures* : sans frais, commissions ni marge, et avec des sinistres plafonnés à 100 000 € ; le prix commercial serait plus élevé.

8 Validation sur échantillon test

8.1 Protocole

Le portefeuille est séparé de façon aléatoire (graine fixée à 42) en 80 % pour l'apprentissage et 20 % pour le test. Les deux GLM sont ré-estimés sur l'échantillon d'apprentissage uniquement, puis la prime pure est prédite sur les contrats du test, qui n'ont pas servi à l'estimation.

8.2 Résultat global

Sur le test, la charge observée est de 10 401 006 € et la charge prédite de 9 715 289 €, soit une **sous-estimation de 6,6 %**. Avec un seul tirage, on ne peut pas dire si cet écart relève du hasard (quelques gros sinistres dans le test suffisent) ou d'un biais ; répéter la séparation avec plusieurs graines permettrait de trancher.

8.3 Calibration par décile de risque

Les contrats du test sont classés en dix groupes de taille voisine selon leur prime prédite (décile 1 : les moins risqués).

Décile	Observé (€)	Prédit (€)	Observé / prédit
1	612 519	559 155	1,10
2	635 360	655 905	0,97
3	859 071	694 281	1,24
4	849 194	747 163	1,14
5	779 081	880 008	0,89
6	854 311	786 927	1,09
7	1 148 310	920 571	1,25
8	1 002 377	1 036 727	0,97
9	1 376 872	1 233 933	1,12
10	2 283 912	2 200 618	1,04

Tab. 8. Charge observée et prédite par décile de prime prédite (échantillon test).

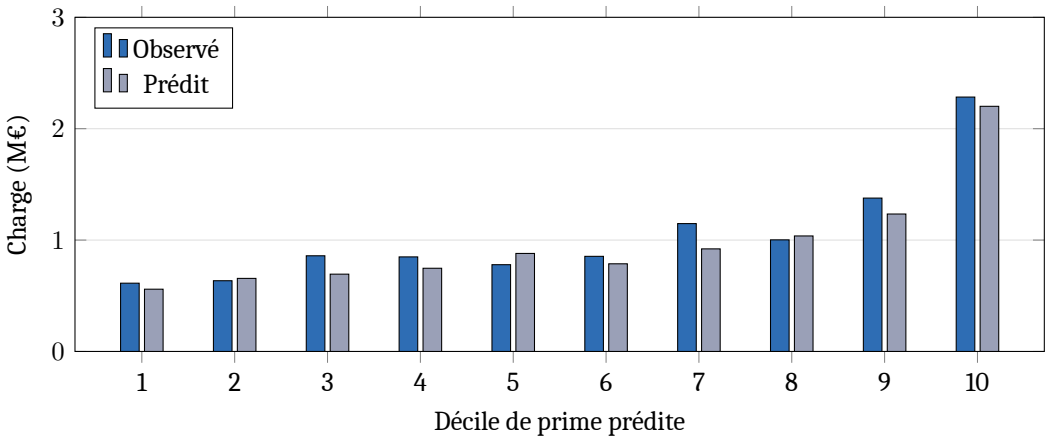


Fig. 2. Charge observée et prédite par décile (échantillon test).

Lecture. Le point fort est le *classement* : la charge observée augmente globalement du décile 1 (0,61 M€) au décile 10 (2,28 M€), soit environ 3,7 fois plus, donc le modèle distingue bien les bons des mauvais risques. Le point faible est la précision par groupe : les rapports observé/prédit varient de 0,89 à 1,25, avec une sous-estimation dans les déciles 3, 4, 7 et 9. Le décile le plus risqué, le plus important pour l'assureur, est bien calé (1,04). Une partie de ces écarts peut provenir du hasard, la charge par décile dépendant de quelques gros sinistres.

9 Comparaison avec XGBoost

9.1 Protocole

XGBoost est entraîné sur la même séparation, avec la même loi (objectif `count:poisson`) et l'exposition en offset. Paramètres : 300 arbres, profondeur maximale 3, taux d'apprentissage 0,05, sous-échantillonnage 0,8. Il reçoit six variables (âge du conducteur, bonus-malus, âge et puissance du véhicule, densité, zone), alors que le GLM n'en utilise que trois. La comparaison porte sur la fréquence, avec la déviance moyenne de Poisson sur le test (plus faible = meilleur).

9.2 Résultats

Indicateur (test)	GLM	XGBoost
Déviance moyenne de Poisson	0,24600	0,24284
Sinistres prédits (observés : 5 400)	5 253 ($-2{,}7\,\%$)	5 296 ($-1{,}9\,\%$)

Tab. 9. GLM contre XGBoost sur la fréquence.

XGBoost réduit la déviance de 1,3 %, un gain modeste. Deux lectures sont possibles : le GLM est suffisant, plus lisible et plus facile à justifier auprès d'un régulateur ; ou le gain vient en partie des variables supplémentaires fournies à XGBoost, et non de la méthode. Un seul tirage ne permet pas de dire si 1,3 % dépasse le hasard. Dans ce contexte, le **GLM est retenu**, le machine learning n'apportant pas ici d'amélioration déterminante.

10 Limites et perspectives

- **Indépendance fréquence–coût** : le produit $\hat{\lambda} \times \hat{\mu}$ suppose cette indépendance, qui n'a pas été testée.
- **Surdispersion** : corrigée par un quasi-Poisson, qui ne modifie pas les primes ; une loi binomiale négative est une alternative.
- **Sinistres graves** : plafonnés à 100 000 €, ce qui retire une partie de la charge réelle ; un traitement séparé de la queue (chargement, loi de Pareto) serait nécessaire en pratique.
- **Écart de comptage** : 36 056 sinistres déclarés contre 26 444 avec montant ; le modèle porte sur ces derniers, et la cause de l'écart n'est pas documentée.
- **Un seul tirage train/test** : les écarts (−6,6 %, gain de 1,3 %) devraient être confirmés par validation croisée ou plusieurs graines.
- **Comparaison non à armes égales** : XGBoost dispose de plus de variables que le GLM.
- **Variables** : l'âge et le bonus-malus sont corrélés ; interactions, splines ou regroupement de classes rares sont des pistes. Par ailleurs, l'usage de certaines variables relève de contraintes éthiques et réglementaires.
- **Prime commerciale** : frais, commissions, marge et chargement de sécurité ne sont pas modélisés.

11 Conclusion

Le modèle collectif à deux GLM permet de construire une prime pure individualisée à partir de la zone, de l'âge et du bonus-malus. Le bonus-malus est de loin le facteur le plus discriminant pour la fréquence, la zone et le jeune âge ajoutent un effet net, et l'âge est le seul facteur qui ressort sur le coût moyen une fois les sinistres extrêmes plafonnés. La démarche a mis en évidence trois points de méthode : la surdispersion de la fréquence (dispersion 2,9), l'effet de quelques sinistres extrêmes sur le modèle de coût, et la nécessité de rendre cohérents les comptages de sinistres entre les deux modèles. Sur données non vues, le classement des risques est cohérent mais la charge est sous-estimée de 6,6 %, et XGBoost n'apporte qu'un gain de 1,3 % : le GLM, plus lisible, constitue ici un choix raisonnable. Les pistes d'amélioration (validation répétée, traitement de la queue, interactions, loi binomiale négative) font l'objet de la section précédente.

A Organisation du code

Source des données. Jeu freMTPL2 (freMTPL2freq et freMTPL2sev), disponible sur OpenML (identifiants 41214 et 41215).

Fichier	Rôle
`telecharger_donnees.py`	téléchargement de freMTPL2 depuis OpenML
`explorer.py`, `analyse1.py`	premier aperçu et statistiques descriptives
`nettoyage.py`	plafonnement, jointure des tables
`analyse2.py`, `analyse3.py`	fréquence par groupe, graphiques
`glm_frequence.py`, `glm_frequence2.py`	GLM de Poisson, surdispersion, quasi-Poisson
`glm_cout2.py`, `verif_gros_sinistres.py`	GLM Gamma initial, diagnostic des gros sinistres
`glm_cout_plafonne.py`	GLM Gamma avec plafonnement (50 000 et 100 000 €)
`prime_pure.py`	prime pure et calage global
`validation.py`	validation train/test par déciles
`xgboost_comparaison.py`	comparaison GLM et XGBoost

Tab. 10. Fichiers du projet (Python 3, pandas, numpy, statsmodels, scikit-learn, XGBoost).